

Predicción de Ingresos

Adult Census Income

Clasificación Binaria: Ingreso mayor a 50.000 USD anuales

Data Science 2

Santiago Suárez Foti

Comisión 86415

0.9307

ROC-AUC

0.73

F1 >50K

87%

Accuracy

XGBoost

Modelo Final

32.562 registros

15 variables

24% positivos (>50K)

Censo USA 1994

Contenido

1.	Descripción del Dataset y Variables
2.	Exploración Univariada — Variables Numéricas
3.	Exploración Univariada — Variables Categóricas
4.	H1 — Educación e Ingreso
5.	H2 — Edad e Ingreso
6.	H3 — Sexo e Ingreso
7.	H4 — Ocupación e Ingreso
8.	H5 — Estado Civil e Ingreso
9.	H6 — Horas Semanales e Ingreso
10.	H7 — País de Origen e Ingreso
11.	Análisis Multivariado 1 — Educación, Sexo e Ingreso
12.	Análisis Multivariado 2 — Región, Educación, Ocupación e Ingreso
13.	Matrices de Correlación
14.	Comparación de Modelos Base
15.	Optimización: Feature Engineering, Target Encoding y XGBoost
16.	Modelo Final — Evaluación y Resultados
17.	Conclusiones

1. Descripción del Dataset y Variables

El dataset proviene del **Censo de Población de Estados Unidos de 1994** (UCI Machine Learning Repository). Contiene **32.562 registros** y **15 variables** demográficas, educativas y laborales. La variable objetivo es binaria: **ingreso = 1** si la persona gana más de 50.000 USD anuales. El dataset presenta **desbalance moderado**: ~24% de casos positivos (>50K) y 76% negativos, lo que requiere usar ROC-AUC y F1-score en lugar de accuracy simple.

■ int — Variable numérica	■ categ. — Variable categórica	■ TARGET — Variable objetivo	■ Excluida — No usada en modelo
Variable	Tipo	Descripción	Rol
edad	int	Edad en años	Predictora
clase_trabajo	categ.	Tipo de empleador (privado, gobierno, autónomo...)	Predictora
peso_final	int	Ponderador estadístico del censo	Excluida (*)
educacion	categ.	Nivel educativo alcanzado	Predictora
años_educacion	int	Años de educación formal cursados (1-16)	Predictora
estado_civil	categ.	Estado civil de la persona	Predictora
ocupacion	categ.	Categoría ocupacional	Predictora
relacion_familiar	categ.	Rol en el núcleo familiar (esposo, hijo, etc.)	Predictora
raza	categ.	Raza/etnia declarada	Predictora
sexo	categ.	Sexo biológico	Predictora
ganancia_capital	int	Ganancias de capital declaradas (USD)	Predictora
perdida_capital	int	Pérdidas de capital declaradas (USD)	Predictora
horas_semana	int	Horas trabajadas por semana	Predictora
pais_origen	categ.	País de nacimiento	Predictora
ingreso	int	TARGET: 1 si >50K USD/año, 0 si ≤50K	Variable objetivo

(*) peso_final es un ponderador estadístico del censo que no tiene correlación con el target (Spearman = -0.01). Se excluye del modelo.

2. Exploración Univariada — Variables Numéricas

Boxplots — Identificación de outliers y dispersión

Boxplots — Variables numéricas



Figura 1: Boxplots de las variables numéricas del dataset.

Observaciones: **edad** tiene mediana 37 años con rango intercuartil entre 28 y 48. Los outliers restantes luego del tratamiento son valores legítimos que se preservaron. **horas_semana** se concentra en 40 horas (jornada estándar) con outliers hacia 99 horas. **ganancia_capital** y **pérdida_capital** tienen mediana 0: distribución bimodal donde ~90% de los registros vale cero y el resto tiene valores legítimamente altos — no se tratan. **años_educacion** está acotado entre 1 y 16 por diseño del censo. **peso_final** tiene valores extremos por diseño estadístico y se excluye del modelo.

Distribuciones — Forma y asimetría




Figura 2: Histogramas con KDE de las variables numéricas.

Observaciones: **edad** muestra distribución bimodal con pico alrededor de los 37-38 años y cola derecha hacia edades mayores. **años_educacion** presenta distribución discreta con picos en 9 (secundaria completa) y 13 (universitario incompleto), reflejando los niveles más comunes del sistema educativo estadounidense. **ganancia_capital** y **pérdida_capital** son extremadamente sesgadas: la inmensa mayoría son cero, con pocos outliers de alto valor. **horas_semana** muestra un pico muy marcado en 40 horas con distribución secundaria en 50 horas.

3. Exploración Univariada — Variables Categóricas




Figura 3: Frecuencia de categorías para las variables categóricas.

Observaciones: **clase_trabajo** está dominada por el sector privado (>70% de los registros). **educacion** muestra que la mayoría tiene secundaria completa (~32%) seguida de universitario incompleto. En **estado_civil**, casado/a domina con ~15.400 casos. La **ocupación** más frecuente es oficios/repuracion (~7.200 registros). En **sexo**, los hombres representan aproximadamente el doble que las mujeres (~22.000 vs ~11.000), reflejando la mayor participación masculina en el mercado laboral de 1994. En **pais_origen** más del 85% corresponde a estados unidos, con México y Filipinas como los países más representados entre inmigrantes.

4. H1 — Educación e Ingreso

Hipótesis: Las personas con mayor nivel educativo tienen mayor probabilidad de ganar >50K.




Figura 4a: Distribución de niveles educativos y proporción >50K por nivel.

Observaciones: Existe un gradiente casi monótono desde primaria incompleta (~3-4% de >50K) hasta doctorado (~73%). Los niveles **licenciatura**, **escuela profesional**, **maestría** y **doctorado** superan la media global del 24% (línea roja punteada), mientras que todos los niveles inferiores a técnico quedan por debajo. El **técnico** (~25%) se sitúa justo en el umbral de la media.




Figura 4b: Probabilidad de >50K según años de educación.

Observaciones: A medida que aumentan los años de educación, la proporción de >50K crece de forma consistente pero no lineal: hay saltos que corresponden a la finalización de cada nivel educativo. El punto de inflexión más claro se observa a partir de los 13 años (licenciatura), donde la probabilidad supera la media global del 24%. Los valores de 15-16 años (maestría y doctorado) alcanzan 73-74%. La línea naranja muestra que los niveles con menos registros (16 años = doctorado) pueden tener estimaciones menos confiables, aunque la tendencia es clara. **Conclusión: Hipótesis CONFIRMADA.**

5. H2 — Edad e Ingreso

Hipótesis: Las personas de mediana edad (35-55) tienen mayor probabilidad de ganar >50K.

H2 — Edad e Ingreso




Figura 5a: Distribución de edad y comparación por nivel de ingreso.

Observaciones: Las personas con ingresos >50K tienen mediana de edad de **43 años** versus 35 años para quienes ganan ≤50K, una diferencia de 8 años. La distribución es bimodal con pico alrededor de los 37-38 años. El rango intercuartil de >50K es más estrecho y desplazado hacia edades intermedias, sugiriendo que el pico de ingresos ocurre en la etapa productiva central.





Figura 5b: Probabilidad de >50K por edad con línea de cantidad de registros.

Observaciones: La línea punteada roja marca el umbral del 30%. La proporción más alta de ingresos altos ($\geq 30\%$) se encuentra en el rango de ~38 a ~61 años, y supera la media global del 24.1% desde los ~33 hasta los ~65 años. En edades muy jóvenes los porcentajes son mínimos y a partir de los 30 años se estabiliza. En edades avanzadas (>70 años) se observa mayor variabilidad que se corresponde con la disminución de la cantidad de registros: **no se puede afirmar** que haya más o menos probabilidad de >50K en edades avanzadas dado el bajo número de casos. **Conclusión:** Hipótesis **CONFIRMADA PARCIALMENTE**.

6. H3 — Sexo e Ingreso

Hipótesis: Los hombres tienen mayor proporción de ingresos >50K que las mujeres, reflejando una brecha salarial de género en 1994.



Observaciones: La hipótesis se **confirma fuertemente**. El 30.6% de los hombres gana >50K frente a solo el 11.0% de las mujeres: una brecha de casi 20 puntos porcentuales. Además, el volumen de hombres en el dataset (~22.000) es el doble que el de mujeres (~11.000), reflejando la participación laboral diferencial de 1994. **Conclusión: Hipótesis CONFIRMADA.**

7. H4 — Ocupación e Ingreso

Hipótesis: Las ocupaciones de mayor calificación tienen mayor proporción de >50K.





Figura 7: Frecuencia de ocupaciones y proporción >50K por ocupación.

Observaciones: ejecutivo/gerente (~49%) y profesional especializado (~46%) lideran claramente, duplicando y triplicando la media global del 24%. servicios de protección sorprende en tercer lugar (~34%). Las barras naranjas superan la media global (línea roja punteada); las grises se ubican por debajo. En el extremo opuesto, servicio doméstico (<2%) y agricultura/pesca (~4%) son los de menor probabilidad. **Conclusión: Hipótesis CONFIRMADA.**

8. H5 — Estado Civil e Ingreso

Hipótesis: Las personas casadas tienen mayor proporción de ingresos >50K.



Observaciones: Las personas **casadas** tienen una proporción de >50K del ~45%, más del doble de la media global (24%) y cuatro veces superior a solteros/as (~10%). Divorciados/as (~11%), viudos/as (~9%) y separados/as (~8%) se ubican muy por debajo. Es una de las variables con mayor poder predictivo del dataset. Este resultado puede reflejar correlación con la edad y el género (la mayoría de casados con altos ingresos son hombres de mediana edad) más que una causalidad directa. **Conclusión: Hipótesis CONFIRMADA fuertemente.**

9. H6 — Horas Semanales e Ingreso

Hipótesis: A mayor cantidad de horas trabajadas por semana, mayor probabilidad de >50K.




Figura 9a: Distribución de horas semanales y comparación por nivel de ingreso.

Observaciones: Ambos grupos ($\leq 50K$ y $> 50K$) tienen **mediana idéntica de 40 horas**. El histograma revela un pico dominante en exactamente 40 horas (> 15.000 registros), con picos secundarios en 45 y 50 horas. Si bien el grupo $> 50K$ muestra mayor dispersión hacia horas extra (IQR más amplio), la concentración excesiva en la jornada típica limita el poder discriminativo de esta variable.




Figura 9b: Probabilidad de >50K según horas trabajadas.

Observaciones: Se observa una asociación positiva hasta aproximadamente 60 horas (donde la probabilidad ronda el 40-50%), pero la relación no es monótona. Los valores extremos muestran alta variabilidad por escasez de datos. El grupo $> 50K$ muestra mayor densidad relativa en horas > 40 , y los $\leq 50K$ concentran más densidad alrededor de 40 horas. La limitación decisiva es la concentración masiva en 40 horas y la escasez de registros en valores extremos, que impide sacar conclusiones robustas. **Conclusión: Hipótesis NO CONFIRMADA** — hay asociación positiva parcial hasta ~60 horas pero no se puede corroborar la hipótesis de forma general.

10. H7 — País de Origen e Ingreso

Hipótesis: Las personas nacidas en EE.UU. no necesariamente tienen mayor proporción de >50K.




Figura 10: Top 10 países por frecuencia y proporción >50K por país (mín. 30 registros).

Observaciones: EE.UU. (~24.5%) es superado por varios países asiáticos: **Irán (~44%)**, **India (~41%)**, **Taiwán (~38%)** y **Japón (~38%)**. Países europeos como Italia, Inglaterra, Canadá y Alemania también superan la media estadounidense. Los países latinoamericanos (México, Cuba, El Salvador) se ubican por debajo. Este patrón refleja que en 1994 los inmigrantes asiáticos llegaban mayoritariamente como profesionales altamente calificados, mientras que los latinoamericanos lo hacían en busca de trabajos de menor calificación. **Conclusión: Hipótesis CONFIRMADA PARCIALMENTE.**

11. Análisis Multivariado 1 — Educación, Sexo e Ingreso




Figura 11: Proporción >50K por nivel educativo, separado por sexo (H1 + H3 combinados).

Observaciones: La brecha de género persiste en **todos los niveles educativos**. En niveles bajos (primaria, secundaria incompleta) ambos grupos tienen proporciones muy bajas, pero la diferencia es visible desde secundaria completa en adelante. En **licenciatura**, los hombres alcanzan ~51% de >50K mientras las mujeres apenas superan el 20%. Incluso en **doctorado**, la proporción femenina (~60%) es menor que la masculina (~80%). En **escuela profesional** (medicina, derecho, odontología), los hombres alcanzan ~80% y las mujeres ~35%. Esto confirma que la educación sola no elimina la brecha salarial de género en 1994: el género es una variable independiente con efecto propio más allá del nivel educativo.

12. Análisis Multivariado 2 — Región, Educación, Ocupación e Ingreso




Figura 12: Proporción >50K por región según nivel educativo y nivel de ocupación (heatmaps).

Observaciones: Ambas matrices muestran una tendencia consistente: a mayor educación y mayor nivel de ocupación, mayor proporción de >50K, independientemente de la región. **Asia con ocupación alta** lidera con 0.55 (55%), muy por encima del resto. **Latinoamérica y Caribe** tiene las proporciones más bajas en todos los niveles — incluso con educación y ocupación alta (0.25 y 0.33 respectivamente), muy inferior al resto de regiones, lo que sugiere barreras estructurales adicionales (idioma, reconocimiento de títulos, discriminación). **Europa y Canadá** presenta el perfil más consistente y equilibrado. **Estados Unidos** tiene proporciones intermedias en todos los cruces.

Radar Charts — Educación, Raza y Región vs Ingreso




Figura 13: Gráficos de radar — proporción >50K por nivel educativo, raza y región.

Observaciones: Los gráficos de radar permiten comparar visualmente el perfil de ingresos dentro de cada variable. En **educación**, el área crece fuertemente hacia educación alta (~43%) y se contrae hacia niveles bajos (~9%), formando un triángulo asimétrico. En **raza**, el grupo asiático/isleño pacífico y blanco/a presentan las áreas más amplias; indígena americano/esquimal y negro/a las más pequeñas. En **región**, Asia y Europa/Canadá muestran vértices más alejados del centro, mientras que Latinoamérica y Caribe tiene el área más reducida, coherente con los hallazgos del análisis multivariado anterior.

13. Matrices de Correlación

Correlación de Spearman — Variables Numéricas con Target




Figura 14: Matriz de correlación de Spearman entre variables numéricas e ingreso.

Se usa **Spearman** porque las variables violan los supuestos de Pearson: distribuciones bimodales, sesgadas y no lineales. **años_educacion** (0.33) tiene la mayor correlación con el target, seguido por **ganancia_capital** (0.28), **horas_semana** (0.27) y **edad** (0.26). Las correlaciones son moderadas porque el ingreso en este dataset depende principalmente de variables categóricas. **peso_final** no tiene correlación (-0.01), confirmando que debe excluirse del modelo.

Asociación Cramér's V — Variables Categóricas vs Ingreso




Figura 15: Asociación de Cramér's V entre variables categóricas e ingreso.

relacion_familiar ($V=0.46$) y **estado_civil** ($V=0.44$) son los predictores más fuertes, seguidos por **educacion** (0.37) y los niveles agrupados (~ 0.34). Las seis variables que superan el umbral de asociación fuerte (0.30 , línea roja) son los predictores clave del modelo. **Sexo** (0.22) y **clase_trabajo** (0.17) tienen asociación moderada. **Raza**, **pais_origen** y **region** se ubican por debajo del 0.15 , indicando asociación débil. Las variables categóricas aportan más señal predictiva que las numéricas, lo que justifica el uso de Target Encoding en el modelo final.

14. Comparación de Modelos Base

Se compararon cinco algoritmos usando **validación cruzada (CV=5)** con **ROC-AUC** como métrica principal. Se eligió ROC-AUC porque con desbalance moderado (~24% positivos) el accuracy solo no es suficiente para evaluar el rendimiento real del clasificador.




Figura 16: Comparación de modelos — ROC-AUC con validación cruzada de 5 folds.

Observaciones: **Gradient Boosting** obtiene el mejor ROC-AUC promedio (~0.921) con la menor variabilidad entre folds, indicando alta estabilidad. **Random Forest** queda segundo (~0.895). **Logistic Regression** (~0.881) es competitiva y más interpretable. **KNN** (~0.875) tiene rendimiento similar a regresión logística pero mayor costo computacional. **Decision Tree** es el peor (~0.769) por su tendencia al overfitting sin regularización. Los métodos de ensemble superan claramente a los modelos simples. Se selecciona **XGBoost** como modelo final por ser la variante optimizada de Gradient Boosting, con regularización nativa y mayor velocidad de entrenamiento.

15. Optimización: Feature Engineering, Target Encoding y XGBoost

Se aplicó un pipeline de optimización en tres etapas para mejorar el rendimiento más allá del Gradient Boosting base (AUC ~0.921). El resultado fue un modelo XGBoost optimizado que alcanzó **AUC = 0.9307**.

Etapla 1 — Feature Engineering

Se crearon 5 variables derivadas que codifican conocimiento de dominio y capturan interacciones no lineales que los modelos tienen dificultad para aprender por sí solos:

Variable creada	Definición	Justificación
tiene_capital	1 si ganancia_capital>0 O pérdida_capital>0	Poseer activos de capital es señal directa de riqueza.
perfil_alto	1 si educación alta Y ocupación alta simultáneamente	Combinación más predictiva que cada condición por separado.
horas_extra	1 si horas_semana > 40	Separa la jornada estándar de quienes trabajan más horas.
edad_productiva	1 si $35 \leq \text{edad} \leq 55$	Rango donde la probabilidad de >50K es máxima según H2.
ocupacion_top	1 si ejecutivo/gerente o profesional especializado	Las dos ocupaciones con mayor proporción de >50K (>45%) unificadas.

Etapla 2 — Target Encoding para variables categóricas

El pipeline base usaba **Label Encoding** (asigna un entero arbitrario a cada categoría), que no transmite información sobre la relación con el target. Se reemplazó por **Target Encoding** (librería *category_encoders*): cada categoría se reemplaza por la **media del target en los datos de entrenamiento**. Esto convierte variables como *relacion_familiar* o *estado_civil* en valores numéricos continuos que capturan directamente su poder predictivo. Para evitar data leakage, el encoder se entrena solo con el train set y se aplica por transformación al test set.

Etapla 3 — XGBoost con GridSearchCV (CV=5)

XGBoost (Extreme Gradient Boosting) es una implementación optimizada de Gradient Boosting que agrega regularización L1/L2 nativa, manejo eficiente de valores ausentes y paralelización. Se optimizaron 5 hiperparámetros mediante **GridSearchCV con CV=5**:

Hiperparámetro	Valores	Efecto sobre el modelo
n_estimators	[200, 300]	Cantidad de árboles; más = mayor capacidad pero riesgo de overfitting.
max_depth	[3, 4, 5]	Profundidad de cada árbol; controla la complejidad de las interacciones.
learning_rate	[0.05, 0.1, 0.2]	Tasa de aprendizaje; valores bajos requieren más árboles pero generalizan mejor.
subsample	[0.8, 1.0]	Fracción de filas por árbol; reduce overfitting vía randomización.
colsample_bytree	[0.8, 1.0]	Fracción de features por árbol; similar al mecanismo de Random Forest.

La búsqueda evaluó $2 \times 3 \times 3 \times 2 \times 2 = 72$ combinaciones con 5 folds cada una (360 entrenamientos en total). La métrica de selección fue ROC-AUC. Adicionalmente, el umbral de clasificación se optimizó mediante la **curva Precision-Recall**,

eligiendo el punto que maximiza el F1-score (umbral óptimo = 0.346, en lugar del 0.5 por defecto).

Mejora de métricas respecto al modelo base

Modelo	ROC-AUC (CV)	Ganancia
Logistic Regression (base)	0.881	— (línea base)
Decision Tree (base)	0.769	−11.2pp vs LR
Random Forest (base)	0.895	+1.4pp vs LR
Gradient Boosting (base)	0.921	+4.0pp vs LR
XGBoost + FE + TargetEnc + GridSearch	0.9307	+5.0pp vs LR +1.0pp vs GB

16. Modelo Final — Evaluación y Resultados




Figura 17: Curva ROC, Precision-Recall y Matriz de Confusión del modelo final XGBoost.

Curva ROC (AUC = 0.93): El modelo discrimina excelentemente entre las dos clases. La curva se aleja rápidamente de la diagonal (clasificador aleatorio), alcanzando alta tasa de verdaderos positivos con baja tasa de falsos positivos.

Curva Precision-Recall (AP = 0.83): Con umbral óptimo de 0.346 (línea roja punteada), el modelo logra un balance precision/recall del ~80%. Usar la curva PR en lugar de solo ROC es más informativo con clases desbalanceadas (~24% positivos).

Matriz de Confusión: De 6.507 casos totales: **4.370 verdaderos negativos** (≤50K correctos), **1.240 verdaderos positivos** (>50K correctos), 569 falsos positivos y 328 falsos negativos. La tasa de acierto global es del 87%, con mejor desempeño en la clase mayoritaria.

Feature Importance — Variables más predictivas




Figura 18: Importancia de variables del modelo final XGBoost.

relacion_familiar es el predictor más importante (30.5%), superando ampliamente a los demás. Su alta importancia se explica porque captura simultáneamente información de género, edad y estado civil. **tiene_capital** (11.3%) y **estado_civil** (11.2%) confirman que poseer activos de capital y el estado civil son señales clave. **educacion** (~9%) y **ganancia_capital** (~6.5%) completan el top 5 junto con **años_educacion** (~5%). Las variables con importancia menor al 5% (línea roja punteada) aportan señal marginal pero se mantienen para la robustez del modelo.

Métricas finales del modelo

Métrica	Valor	Interpretación
---------	-------	----------------

ROC-AUC	0.9307	Excelente capacidad discriminativa — supera el objetivo de 0.90.
F1 clase >50K	0.73	Buen balance precision/recall para la clase minoritaria.
Precisión >50K	0.73	De cada 100 predichos como >50K, 73 son correctos.
Recall >50K	0.74	Se detecta el 74% de los casos reales de >50K.
Accuracy	0.87	87% de clasificaciones correctas sobre el total.
Umbral óptimo	0.346	Ajustado por curva PR para maximizar F1 en clase positiva.

17. Conclusiones

Resumen de hipótesis

H1 — Educación	CONFIRMADA	Gradiente monótono desde 3-4% (primaria incompleta) hasta 73-74% (maestría/doctorado). Punto de inflexión clave en licenciatura (13 años).
H2 — Edad	PARCIAL	Rango de mayor probabilidad: ~38 a 61 años ($\geq 30\%$). No se puede afirmar sobre edades avanzadas por escasez de registros. Mediana >50K: 43 años vs 35 en $\leq 50K$.
H3 — Sexo	CONFIRMADA	Hombres 30.6% vs mujeres 11.0%. Brecha de ~20pp que persiste en todos los niveles educativos, incluso en doctorado.
H4 — Ocupación	CONFIRMADA	Ejecutivo/gerente (~49%) y profesional especializado (~46%) lideran. Servicio doméstico (<2%) en el extremo opuesto.
H5 — Estado civil	CONFIRMADA	Casados/as (~45%) tienen más del doble del promedio global (24%). Solteros/as (~10%) muy por debajo. Una de las variables más predictivas.
H6 — Horas	NO CONFIRMADA	Misma mediana (40h) en ambos grupos. Asociación positiva parcial hasta ~60h pero la concentración masiva en 40h impide confirmar la hipótesis.
H7 — País origen	PARCIAL	EE.UU. (24.5%) superado por Irán (44%), India (41%), Taiwán y Japón (38%). Los inmigrantes latinoamericanos quedan por debajo de la media.

Hallazgos del Análisis Multivariado

Los inmigrantes asiáticos con alta ocupación superan en proporción de >50K a los estadounidenses nativos (0.55 vs 0.47). Los inmigrantes latinoamericanos tienen menor proporción en todos los niveles de educación y ocupación, sugiriendo barreras estructurales adicionales (idioma, reconocimiento de títulos, discriminación) más allá de la calificación.

Resultado del Modelado

El modelo final **XGBoost + Target Encoding** alcanzó un **ROC-AUC de 0.9307**, superando el objetivo de 0.90 y mejorando en +5pp respecto a la línea base (Logistic Regression). Las variables más predictivas son **relacion_familiar** (30.5%), **tiene_capital** (11.3%) y **estado_civil** (11.2%). El modelo es estable entre folds de validación cruzada y detecta el 74% de los casos de ingresos altos (recall).

Limitaciones

- Dataset de 1994 — los patrones socio-económicos han cambiado significativamente.
- El desbalance moderado (24%/76%) requiere monitoreo del umbral según el caso de uso.
- Variables relevantes como patrimonio total o historial crediticio no están disponibles.
- relacion_familiar tiene alta correlación con género, lo que puede introducir sesgos en aplicaciones reales.